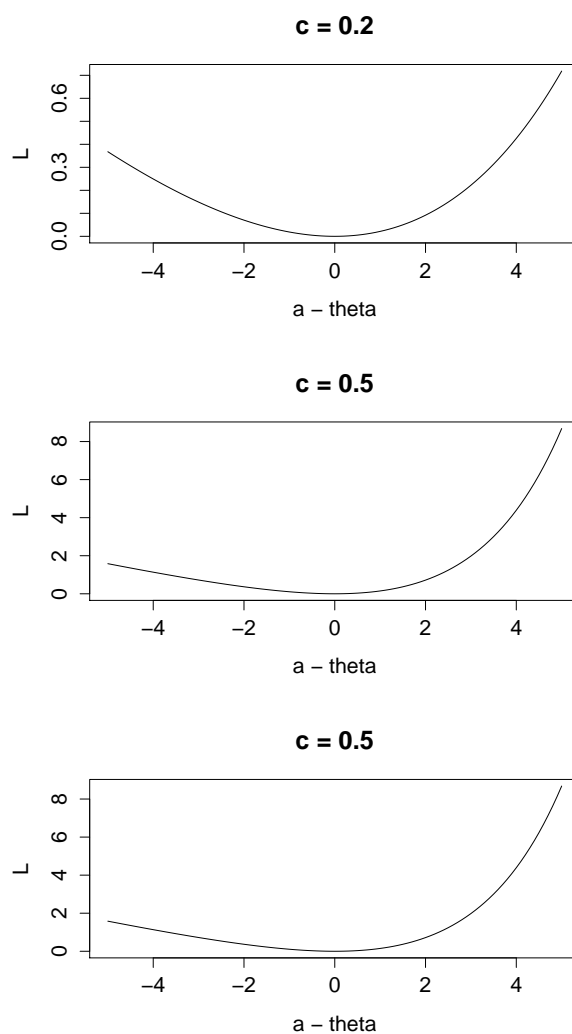


1 损失函数作业

7.65

(a) 画出函数图像如下:



可见随着 c 的增加, 函数图像逐渐由对称变得不对称。

$$(b) \quad E(L(\theta, \delta) | \mathbf{x}) = e^{c\delta} E(e^{-c\theta} | \mathbf{x}) - c(\delta - E(\theta | \mathbf{x})) - 1$$

$$\text{求导可得 } ce^{c\delta} E(e^{-c\theta} | \mathbf{x}) - c = 0 \Rightarrow \delta = -\frac{1}{c} \log E(e^{-c\theta} | \mathbf{x})$$

而 $ce^{c\delta}E(e^{-c\theta}|\mathbf{x}) - c$ 随 δ 的单调递增, 故极值为极小值, 满足要求, 即:

$$\delta^\pi(x) = -\frac{1}{c} \log E(e^{-c\theta}|\mathbf{x})$$

(c) 这里的 $\pi(\theta)$ 代表全实轴的均匀分布函数, 可先设 $\pi(\theta) = \frac{1}{D}$ 最后令 $D \rightarrow \infty$ (其实后面的计算与 D 无关)

$$f(\mathbf{x}, \theta) = C e^{-\sum_{i=1}^n \frac{(x_i - \bar{x})^2}{2\sigma^2}} e^{-\frac{n(\bar{x} - \theta)^2}{2\sigma^2}} = p(\mathbf{x}) e^{-\frac{n(\bar{x} - \theta)^2}{2\sigma^2}}$$

$$m(\mathbf{x}) = \int f(\mathbf{x}|\theta) \pi(\theta) d\theta = p(\mathbf{x}) \int e^{-\frac{n(\bar{x} - \theta)^2}{2\sigma^2}} d\theta$$

$$\pi(\theta|\mathbf{x}) = \frac{f(\mathbf{x}, \theta)}{m(\mathbf{x})} = \frac{e^{-\frac{n(\bar{x} - \theta)^2}{2\sigma^2}}}{\int e^{-\frac{n(\bar{x} - \theta)^2}{2\sigma^2}} d\theta}$$

即 $\pi(\theta|\mathbf{x}) \sim n(\bar{x}, \frac{\sigma^2}{n})$ 可以得到

$$E(e^{-c\theta}|\mathbf{x}) = M_{\theta|\mathbf{x}}(-c) = e^{-c\bar{x} + \frac{c^2\sigma^2}{2n}}$$

$$\delta^B(\bar{X}) = \bar{X} - \frac{c\sigma^2}{2n}$$

$$(d) \quad E(\theta|\mathbf{x}) = \bar{x}$$

$$E(L(\theta, \delta^B)|\mathbf{x}) = e^{c\delta} E(e^{-c\theta}|\mathbf{x}) - c(\delta - E(\theta|\mathbf{x})) - 1 = \frac{c^2\sigma^2}{2n}$$

$$E(L(\theta, \bar{x})|\mathbf{x}) = e^{c\bar{x}} E(e^{-c\theta}|\mathbf{x}) - c(\bar{x} - E(\theta|\mathbf{x})) - 1 = e^{\frac{\sigma^2 c^2}{2n}} - 1$$

$$(e) \quad L_2(\theta, a) = |\theta - a|^2$$

$$E(L_2(\theta, \delta^B)|\mathbf{x}) = E\left[(\bar{x} - \theta)^2 + \left(\frac{c\sigma^2}{2n}\right)^2 - 2(\bar{x} - \theta)\frac{c\sigma^2}{2n} \middle| x\right] = \frac{\sigma^2}{n} + \left(\frac{c\sigma^2}{2n}\right)^2$$

$$E(L_2(\theta, \bar{x})|\mathbf{x}) = E\left[(\bar{x} - \theta)^2 \middle| x\right] = \frac{\sigma^2}{n}$$

7.66

$$(a) \quad \because n\bar{X} \sim B(n, \theta) \text{Var}(n\bar{X}) = E(n\bar{X})^2 - (En\bar{X})^2 \neq \theta^2$$

$$(b) \quad \therefore E\bar{X}^2 = \frac{1}{n^2} E(n\bar{X})^2 = \frac{1}{n^2} [n\theta(1-\theta) + n^2\theta^2] = \theta^2 + \frac{\theta(1-\theta)}{n}$$

$$T_n = \bar{X}^2$$

$$T_n^{(i)} = \left(\frac{\sum_{k=1}^n X_k - X_i}{n-1}\right)^2 = \left(\frac{\sum_{k=1}^n X_k}{n-1}\right)^2 + \left(\frac{X_i}{n-1}\right)^2 - \frac{2X_i(\sum_{k=1}^n X_k)}{(n-1)^2}$$

$$\sum_{i=1}^n T_n^{(i)} = \frac{(n-2)(\sum_{k=1}^n X_k)^2 + \sum_{i=1}^n X_i^2}{(n-1)^2} = \frac{(n-2)n^2 T_n + \sum_{i=1}^n X_i^2}{(n-1)^2}$$

$$\begin{aligned} JK(T_n)1 &= nT_n - \frac{n-1}{n} \sum_{i=1}^n T_n^{(i)} \\ &= nT_n - \frac{n(n-2)T_n}{n-1} - \frac{\sum_{i=1}^n X_i^2}{n(n-1)} \\ &= \frac{n}{n-1} T_n - \frac{\sum_{i=1}^n X_i^2}{n(n-1)} \end{aligned}$$

而对 0-1 分布 $X_i = X_i^2$, 故 $JK(T_n) = \frac{n}{n-1} T_n - \frac{\bar{X}}{(n-1)}$

(c) $EJK(T_n) = \frac{n}{n-1}(\theta^2 + \frac{\theta(1-\theta)}{n}) - \frac{\theta}{n-1} = \theta$

(d) 伯努利分布属于指数分布族, 易知 \bar{X} 为 θ 的完全充分统计量。

而 $JK(T_n) = \frac{n}{n-1} \bar{X}^2 + \frac{\bar{X}}{n-1}$ 是 \bar{X} 的函数, 因此 $JK(T_n)$ 是 θ^2 的最佳无偏估计


随机试验验证 利用 R 生成随机数, 选取 $\theta = 0.3, 0.5, 0.7$, 分别生成 10 个随机数 (n 不能选的太大, 否则 $\frac{\theta(1-\theta)}{n}$ 趋近 0 而看不出区别), 计算估计量 $T_n, JK(T_n)$, 并重复 10000 次, 再计算这 10000 次的平均值, 可以验证上题的 (a),(c) 两小问。

mean	$\theta = 0.3$	$\theta = 0.5$	$\theta = 0.7$
θ^2	0.09	0.25	0.49
T_n	0.11179	0.27567	0.51027
JKT_n	0.09072	0.25066	0.48928



T_n 的平均值明显比 θ^2 要大, 而 JKT_n 的平均值与 θ^2 很接近。

2 随机模拟：密度函数的估计

1 求出 C 的值为 $C = 1.0001397$, f 的函数图像如下:



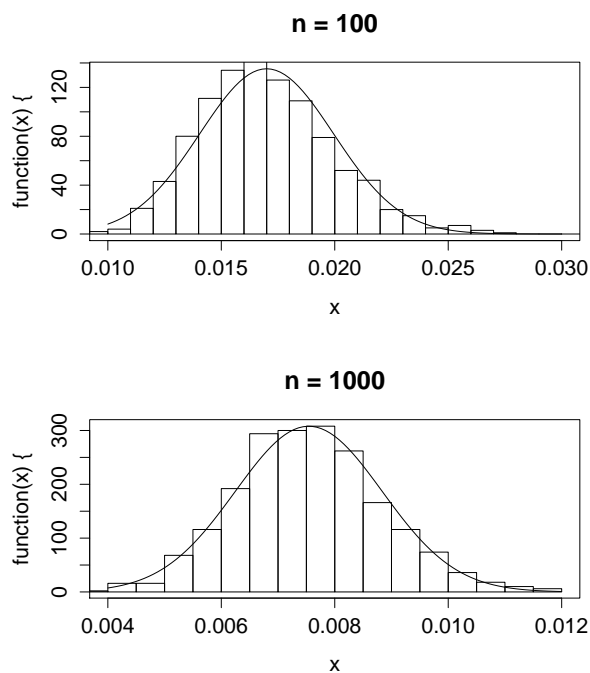
2 将密度函数与直方图画在一张图上，可以看到抽样结果应当是正确的：



3 计算出 1000 次模拟所得的 RAISE 值得均值和方差为如下表所示

RAISE	mean	sd
n = 100	0.01691	0.00301
n = 1000	0.00750	0.00129

而且可以发现 RAISE 的分布基本服从正态分布 (证明显得有些困难)。直方图如下



可以看出取样数量 n 越大, 密度函数的估计越好。这从直观上也容易理解, 样本越多, 对应取得的可以取得的 h 越小, 密度函数的估计越接近真实的密度函数。